



دانشگاه علم و صنعت ایران - دانشکده مهندسی کامپیوتر

آزمایش هشتم آزمایشگاه معماری کامپیوتر

موضوع: پروژه جبر خطی

استاد: دکتر امید نیکان

تهیه کنندگان:

ایلیا صادق احمدی

محمد منتظری

شاهین شاپورزاده

سیدعلیرضا حسینی

سؤال ۷ — خواندن دادگان و پیش‌پردازش متون

سؤال ۸ — ۳۰ کلمه پرتکرار

سؤال ۹ — نمودار ابر کلمات (Word Cloud)

سؤال ۱۰ — ساخت ماتریس کوله کلمات (Bag of Words)

سؤال ۱۱ — استانداردسازی و تجزیه SVD

سؤال ۱۲ — تعیین آستانه برش و اجرای SVD Truncated

سؤال ۱۳ — پیاده‌سازی Randomized SVD

سؤال ۱۴ — اجرای Randomized SVD و مقایسه با SVD Truncated

سؤال ۱۵ — تفسیر مؤلفه‌های نهان (Concepts)

سؤال ۱۶ — شباهت جفت کلمات در فضای نهان

سؤال ۱۷ — شباهت متن با کلمات منتخب در فضای نهان

سؤال ۱۸ — جست‌وجوی معنایی در فضای نهان

سؤال ۱۹ — بردار نهان میانگین هر دسته و پیشنهاد روش برچسب‌گذاری

سؤال ۲۰ — پیاده‌سازی و ارزیابی روش برچسب‌گذاری روی داده آزمون

سؤال ۷ — خواندن دادگان و پیش پردازش متون

فایل dataset.csv شامل دو ستون است:

- Text: متن خبر
- Label: برچسب موضوعی خبر (۰ تا ۴)

پیش پردازش متون شامل مراحل زیر است:

۱. کوچک کردن تمامی حروف (lowercase)
 ۲. حذف علائم نگارشی و کاراکترهای غیرحرفی مانند اعداد و نشانه‌ها
 ۳. یکدست سازی فاصله‌های خالی (whitespace)
- ابعاد دادگان خوانده شده برابر با (۲×۲۲۲۵) است؛ یعنی ۲۲۲۵ خبر که هر یک دارای متن خام و برچسب موضوعی است.

سؤال ۸ — ۳۰ کلمه پرتکرار

با شمارش تمامی کلمات موجود در تمام متون (پس از پیش پردازش)، ۳۰ کلمه پرتکرار استخراج و نمودار ستونی فراوانی آن‌ها رسم شده است. ده کلمه نخست این فهرست به شرح زیر است:

ردیف	کلمه	فراوانی
1	the	52636
2	to	25113
3	of	20008
4	and	18612
5	a	18343
6	in	17734
7	s	9310
8	for	8945
9	is	8555
10	that	8257

آیا دانستن تعداد این کلمات در یک خبر، کمکی به درک موضوع آن خبر می‌کند؟

خیر. همان‌طور که در نمودار مشخص است، کلمات پرتکرار عمدتاً کلمات ربط، حروف اضافه و افعال کمکی/اسنادی پرکاربرد زبان انگلیسی هستند (مانند the, to, of, and, a, in, is و...). این کلمات تقریباً در همه متون با فراوانی بالا و مشابه ظاهر می‌شوند و به موضوع خاص یک متن مرتبط نیستند؛ بنابراین دانستن تعداد تکرار آن‌ها اطلاعات تمایزدهنده‌ای درباره موضوع خبر نمی‌دهد. برای درک موضوع، باید به کلمات کلیدی و پرمعناتر (مانند اسامی خاص یا کلمات موضوعی) توجه کرد، نه پرتکرارترین کلمات کل دادگان.

سؤال ۹ — نمودار ابر کلمات (Word Cloud)

برای ساخت ابر کلمات معنادار، معمولاً کلمات توقف (Stop Words — کلمات بسیار پرتکرار و کم‌معنا مانند the, is, and و...) حذف می‌شوند تا کلمات کلیدی و پرمعناتر متون نمایان شوند. اندازه هر کلمه در ابر کلمات متناسب با فراوانی (یا اهمیت) آن کلمه در متن است.

پس از حذف کلمات توقف، ده کلمه برتر به شرح زیر به دست آمد:

ردیف	کلمه	فراوانی
1	year	2310
2	people	2045
3	can	1671
4	last	1394
5	first	1355
6	time	1322
7	world	1201
8	government	1160
9	now	1145
10	years	1003

تفسیر نمودار و معیار انتخاب کلمات

در الگوریتم ابر کلمات، معیار اصلی برای انتخاب و بزرگ‌نمایی هر کلمه، فراوانی تکرار آن در کل متون است (پس از حذف کلمات توقف و علائم نگارشی)؛ هرچه کلمه‌ای بیشتر تکرار شده باشد، با فونت بزرگ‌تر و معمولاً رنگ پررنگ‌تری نمایش داده می‌شود.

موقعیت قرارگیری کلمات معمولاً تصادفی است و اهمیت معنایی خاصی ندارد. با نگاه به ابر کلمات می‌توان به سرعت موضوعات و مفاهیم غالب در مجموعه متون را حدس زد؛ کلماتی مانند year, people, government, game که در نمودار درشت‌تر دیده می‌شوند، نشان‌دهنده محورهای اصلی محتوای خبری این دادگان (مانند سیاست، ورزش و اقتصاد) هستند.

سؤال ۱۰ — ساخت ماتریس کوله کلمات (Bag of Words)

فایل words.csv شامل مجموعه‌ای از ۵۲ کلمه منتخب (به ترتیب حروف الفبا) است که با همان روش استخراج کلمات ابر کلمات به‌دست آمده‌اند. برای هر متن، تعداد تکرار هر یک از این کلمات شمارش شده و ماتریس کوله کلمات (BW) ساخته شده است؛ ماتریسی با ابعاد (تعداد متون $\times$ تعداد کلمات منتخب) که درایه آن، یعنی $BW[i, j]$ ، تعداد تکرار کلمه ستون j ام در متن (سطر) i ام است.

ماتریس کوله کلمات ساخته‌شده، ابعادی برابر با (52×2225) دارد؛ یعنی به ازای هر یک از ۲۲۲۵ متن دادگان، یک بردار ۵۲ بعدی (متناظر با ۵۲ کلمه منتخب فایل words.csv) ساخته شده که هر درایه آن، تعداد تکرار کلمه مربوطه در آن متن است. این ماتریس در سؤالات بعدی (استانداردسازی و تجزیه SVD) مورد استفاده قرار می‌گیرد.

تفکیک داده‌های آموزش و آزمون

طبق دستور پروژه، ۲۰۰۰ ردیف اول داده‌ها به‌عنوان داده آموزش جدا شده و ۲۲۵ ردیف باقی‌مانده به‌عنوان داده آزمون کنار گذاشته شده است. از این پس تا سؤال ۱۸ تنها روی داده‌های آموزش کار می‌شود. ابعاد این دو مجموعه به شرح زیر است:

مجموعه	ابعاد ماتریس کوله کلمات
داده‌های آموزش (Train)	52×2000
داده‌های آزمون (Test)	52×225

سؤال ۱۱ — استانداردسازی و تجزیه SVD

ابتدا بردارهای کوله کلمات (ستون‌های ماتریس آموزش) استاندارد می‌شوند؛ یعنی از هر ستون میانگین آن کم و بر انحراف معیار آن تقسیم می‌شود تا هر کلمه میانگین صفر و واریانس واحد داشته باشد:

$$X_{:,j} = (BW_{:,j} - \mu_j) / (\sigma_j)$$

این کار لازم است چون کلمات پرتکرار (مانند new یا time) واریانس بسیار بزرگتری نسبت به کلمات کم‌تکرار دارند و بدون استاندارد کردن، تجزیه SVD عمدتاً تحت تأثیر مقیاس همین چند کلمه پرتکرار قرار می‌گیرد، نه ساختار همبستگی واقعی میان تمام کلمات.

سپس تجزیه SVD اقتصادی (Economy / Thin SVD) روی ماتریس استاندارد شده اعمال شده است. از آنجا که تعداد کلمات (۵۲) بسیار کمتر از تعداد اسناد (۲۰۰۰) است، محاسبه SVD کامل (که در آن U ابعاد 2000×2000 می‌داشت) از نظر حافظه و محاسبات غیرضروری است؛ در SVD اقتصادی تنها بخش مفید U (با ابعاد 52×2000) محاسبه می‌شود که اطلاعات یکسانی با حالت کامل دارد، زیرا ستون‌های حذف‌شده U متناظر با مقادیر تکین صفر هستند و در بازسازی ماتریس نقشی ندارند.

ابعاد ماتریس‌های حاصل از این تجزیه:

ابعاد	توضیح	ماتریس
52×2000	ماتریس استاندارد شده	X
52×2000	اسناد – مفاهیم	U
۵۲	بردار مقادیر تکین	Σ
52×52	مفاهیم – کلمات	V^T

سؤال ۱۲ — تعیین آستانه برش و اجرای SVD Truncated

برای تعیین تعداد مؤلفه‌های مناسب (c)، نمودار مقادیر تکین (Scree Plot) رسم شده و نقطه زانویی (Elbow Point) روی آن یافته شده است؛ نقطه‌ای که پس از آن، افت مقادیر تکین به‌شدت کند می‌شود و مؤلفه‌های بعدی سهم اندکی در بازسازی اطلاعات دارند.

برای پیدا کردن نقطه زانویی به‌صورت خودکار، از روش فاصله عمودی هر نقطه تا خط واصل بین اولین و آخرین مقدار تکین استفاده شده است؛ نقطه‌ای که بیشترین فاصله را تا این خط دارد، به‌عنوان زانو در نظر گرفته می‌شود.

تعداد مؤلفه پیشنهادی برای برش با این روش برابر با $c = 13$ به دست آمد.

با این آستانه، SVD Truncated روی ماتریس‌های به‌دست‌آمده از سؤال قبل اجرا شده است:

ابعاد	ماتریس برش خورده
13×2000	U
۱۳	Σ
52×13	V^T

خطای بازسازی نسبی (Relative Reconstruction Error) این تجزیه برابر است با:

$$\|X - \tilde{X}\|_F / \|X\|_F = 0.7384$$

سؤال ۱۳ — پیاده‌سازی Randomized SVD

شبه‌کد الگوریتم Randomized SVD (بر پایه روش Halko و همکاران) به شرح زیر پیاده‌سازی شده است:

۱. یک ماتریس تصادفی گاوسی Ω با ابعاد $n \times l$ بسازید ($l = \text{rank} + \text{oversample}$).
۲. ماتریس $Y = A\Omega$ را محاسبه کنید (تصویر تصادفی ماتریس A).
۳. (اختیاری، برای دقت بیشتر) چند بار تکرار توانی (Power Iteration) انجام دهید: $Y \leftarrow \text{orth}(A^T Y)$ سپس $Y \leftarrow \text{orth}(AY)$.
۴. با تجزیه QR، پایه متعامد Q برای فضای ستونی Y بیابید؛ Q تقریبی از فضای ستونی A است.
۵. ماتریس کوچک $B = Q^T A$ را بسازید (ابعاد $l \times n$ ، بسیار کوچک‌تر از A).
۶. تجزیه SVD دقیق روی B انجام دهید: $B = U \Sigma V^T$.
۷. ماتریس بردارهای تکین چپ اصلی را با $U = Q \hat{U}$ بازیابی کنید.
۸. خروجی نهایی را به رتبه موردنظر برش دهید.

سؤال ۱۴ — اجرای Randomized SVD و مقایسه با SVD Truncated

تابع Randomized SVD با رتبه متناظر با آستانه پیشنهادی ($c = 13$) روی ماتریس کوله کلمات اجرا و خطای بازسازی آن با SVD Truncated مقایسه شده است:

خطای بازسازی نسبی	روش
0.7384	SVD Truncated (دقیق)

خطای بازسازی نسبی	روش
0.7455	Randomized SVD
0.0071	تفاضل خطا

مقایسه و انتخاب روش

همان‌طور که مشاهده می‌شود، خطای بازسازی Randomized SVD تقریباً برابر با خطای SVD Truncated (دقیق) است؛ چراکه برای ماتریسی با ابعاد مناسب مقادیر تکین، تصویر تصادفی به‌خوبی فضای ستونی اصلی را پوشش می‌دهد و تکرار توانی نیز دقت را به تجزیه دقیق نزدیک‌تر می‌کند.

تفاوت اصلی این دو روش در **هزینه محاسباتی** است. تجزیه دقیق SVD روی یک ماتریس $n \times m$ هزینه‌ای از مرتبه $\min(m,n) \cdot O(mn)$ دارد، درحالی‌که Randomized SVD با کاهش ابتدایی ماتریس به یک زیرفضای تصادفی با ابعاد کوچک $\min(m,n) \gg 1$ ، هزینه را به مرتبه $O(mn)$ کاهش می‌دهد؛ همچنین ضرب‌های ماتریسی درگیر در این روش (برخلاف تجزیه دقیق) به‌خوبی قابل موازی‌سازی و توزیع روی چند پردازنده/ماشین هستند.

در نتیجه، اگر دادگان ما شامل تمام متون موجود در اینترنت بود (یعنی ماتریس کوله کلمات بسیار بزرگ با میلیون‌ها سند و کلمه)، **Randomized SVD گزینه مناسب‌تری** خواهد بود؛ زیرا با دقتی بسیار نزدیک به تجزیه دقیق، امکان تجزیه چنین ماتریس‌های عظیمی را در زمان و حافظه‌ای بسیار کمتر (و به‌صورت مقیاس‌پذیر و موازی) فراهم می‌کند، درحالی‌که تجزیه دقیق SVD برای این ابعاد از نظر محاسباتی عملاً غیرقابل اجرا می‌شود.

سؤال ۱۵ — تفسیر مؤلفه‌های نهان (Concepts)

برای هر یک از ۱۳ مؤلفه حاصل از SVD Truncated (سطرهای ماتریس مفاهیم-کلمات $\tilde{V}^T$)، ۵ کلمه‌ای که بیشترین قدر مطلق را در آن راستا دارند (یعنی بیشترین سهم را در تعریف آن مفهوم دارند) یافته شده‌اند. علامت هر مقدار نیز جهت کلمه را در آن راستا نشان می‌دهد؛ کلمات با علامت یکسان در یک مفهوم هم‌جهت‌اند و کلمات با علامت مخالف در تقابل با هم قرار دارند.

مؤلفه	۵ کلمه برتر (با ضریب)
۱	,election (+0.36), labour (+0.35), party (+0.27), minister (+0.27) technology (−0.23)
۲	,government (+0.24), digital (+0.23), technology (+0.23), uk (+0.22) mobile (+0.21)

مؤلفه	۵ کلمه برتر (با ضریب)
۳	time (+0.34), win (+0.30), play (+0.29), game (+0.28), won (+0.25)
۴	artist (-0.34), music (-0.34), won (-0.33), film (-0.30), game (+0.29)
۵	film (-0.29), deal (+0.27), director (-0.23), company (+0.21), group (+0.21)
۶	growth (+0.50), economy (+0.44), expected (+0.24), million (+0.21), market (+0.17)
۷	director (-0.29), government (-0.28), home (-0.28), film (-0.27), law (-0.27)
۸	director (+0.39), film (+0.31), firm (+0.28), company (+0.28), home (-0.25)
۹	help (+0.30), new (-0.29), money (+0.27), home (-0.22), work (+0.22)
۱۰	club (+0.45), money (+0.37), deal (+0.31), phone (+0.30), mobile (+0.30)
۱۱	high (-0.44), technology (-0.28), phone (+0.27), service (+0.25), number (+0.24)
۱۲	sale (-0.32), economy (+0.29), uk (-0.29), tax (+0.26), online (-0.25)
۱۳	chief (+0.47), france (-0.31), number (-0.30), group (-0.25), law (+0.22)

حدس معنای برخی مفاهیم

- مفهوم ۱: سیاست / انتخابات (election, labour, party, minister)
- مفهوم ۲: فناوری و دولت الکترونیک (government, digital, technology, mobile)
- مفهوم ۳: ورزش و بازی (time, win, play, game, won)
- مفهوم ۴: هنر و موسیقی در برابر بازی (game در برابر artist, music, won, film)
- مفهوم ۵: سینما و کسب و کار رسانه (film, deal, director, company)
- مفهوم ۶: اقتصاد کلان (growth, economy, expected, million, market)

سایر مفاهیم ترکیبی از چند حوزه (فناوری موبایل، حقوقی-اداری، تجارت خرده‌فروشی و...) هستند و تفکیک آن‌ها به یک برچسب واحد دشوارتر است؛ این امری طبیعی در LSI است، چون مؤلفه‌ها لزوماً بر محورهای معنایی «تمیز و انسانی» منطبق نیستند، بلکه جهت‌های آماری بیشترین واریانس مشترک کلمات‌اند.

سؤال ۱۶ — شباهت جفت کلمات در فضای نهان

بردار تعبیه هر کلمه، همان ستون متناظر آن در ماتریس مفاهیم-کلمات برش‌خورده ($\tilde{V}^T$) است (بردار c بعدی). دو معیار زیر برای جفت کلمات خواسته‌شده محاسبه شده است:

$$\text{Cosine Similarity}(u, v) = (u \cdot v) / (\|u\| \|v\|) \in [-1, 1]$$

$$\text{Euclidean Distance}(u, v) = \|u - v\|_2 \in [0, \infty)$$

Cosine Similarity نزدیک به ۱ یعنی دو بردار تقریباً هم‌جهت‌اند (مفهوماً بسیار نزدیک)، نزدیک به ۰ یعنی بی‌ارتباطی (تقریباً عمود)، و نزدیک به -۱ یعنی دو بردار در تقابل معنایی‌اند. Euclidean Distance هرچه کوچک‌تر باشد بردارها به هم نزدیک‌ترند و بزرگ‌تر بودنش نشانه دوری بیشتر در فضای نهان است (کمینه آن صفر و بیشینه‌اش نامحدود است).

کلمه اول	کلمه دوم	Cosine Similarity	Euclidean Distance
mobile	technology	0.3426	0.6305
director	film	0.9714	0.1536
win	won	0.7218	0.3573
play	game	0.9531	0.1562
play	law	-0.2220	0.7897
government	music	0.0042	0.7845

تفسیر نتایج

- **(director, film)** و **(play, game)** بیشترین شباهت کسینوسی (نزدیک به ۱) و کمترین فاصله اقلیدسی را دارند؛ این دو جفت به‌طور طبیعی در متون خبری در کنار هم و در بافت مشابهی (سینما و ورزش/بازی) ظاهر می‌شوند.
- **(win, won)** نیز شباهت نسبتاً بالایی دارد که منطقی است چون دو صورت یک فعل هستند و در مفاهیم مشابهی (نتایج مسابقات) به کار می‌روند.

- (mobile, technology) شباهت متوسطی دارد؛ هر دو به حوزه فناوری مرتبطاند اما هر کدام در مؤلفه‌های نهان کمی متفاوتی برجسته می‌شوند (یکی بیشتر در محور تجاری/مصرفی و دیگری در محور دولت الکترونیک).

- (play, law) و (government, music) کمترین شباهت (حتی منفی) و بیشترین فاصله را دارند؛ این دو جفت از نظر معنایی و موضوعی (سرگرمی/ورزش در برابر حقوق و سیاست/موسیقی) کاملاً بی‌ارتباط یا متضادند که با شهود ما همخوانی دارد.

به‌طور کلی هرچه دو کلمه در متون خبری بیشتر در بافت‌های مشابه ظاهر شوند، در فضای نهان به هم نزدیک‌تر (شباهت کسینوسی بالاتر و فاصله اقلیدسی کمتر) قرار می‌گیرند؛ این دقیقاً همان رابطه معنایی پنهانی است که LSI سعی در استخراج آن دارد.

سؤال ۱۷ — شباهت متن با کلمات منتخب در فضای نهان

طبق صورت پروژه، متنی که شماره آن (index) است انتخاب و معیار Cosine Similarity بین بردار نهان این متن (سطر متناظر در $\tilde{U}$) و بردار نهان تک‌تک ۵۲ کلمه منتخب (ستون‌های $\tilde{V}^T$) محاسبه و به‌صورت نمودار ستونی عریض رسم شده است. سپس تعداد تکرار هر یک از این کلمات در همان متن، در نموداری مشابه زیر آن نمایش داده شده است.

مقایسه دو نمودار

متن نمونه بالا درباره سیاست/انتخابات است. همان‌طور که مشاهده می‌شود، کلماتی مانند labour, election, party, minister, government, tax هم در نمودار تکرار خام بالا هستند و هم در نمودار شباهت کسینوسی در فضای نهان مقدار بالایی می‌گیرند؛ اما این دو نمودار کاملاً یکسان نیستند:

- برخی کلمات که اصلاً در متن تکرار نشده‌اند (تکرار = ۰)، مانند country یا work، در فضای نهان شباهت مثبت و قابل‌توجهی با متن نشان می‌دهند؛ چون هرچند این کلمات به‌صورت لفظی در متن نیامده‌اند، اما در مفهومی (سیاست/دولت) که این متن قویاً به آن تعلق دارد نقش دارند. این دقیقاً همان کشف رابطه پنهان معنایی است که هدف اصلی LSI است و بردار خام کوله کلمات از تشخیص آن ناتوان است.

- برعکس، ممکن است کلمه‌ای با تکرار کم اما نامرتبط با مفهوم غالب متن، در فضای نهان شباهت پایین یا حتی منفی داشته باشد.

بنابراین فضای نهان اطلاعاتی فراتر از شمارش ساده کلمات در اختیار می‌گذارد و می‌تواند ارتباط مفهومی متن با کلماتی را نشان دهد که به‌صورت لفظی در آن ظاهر نشده‌اند.

سؤال ۱۸ — جست‌وجوی معنایی در فضای نهان

اگر بخواهیم کلمه technology را در یک پایگاه داده متنی جست‌وجو کنیم، رویکرد سنتی کوله کلمات تنها متونی را مرتبط تشخیص می‌دهد که این کلمه دقیقاً و لفظاً در آن‌ها تکرار شده باشد. اگر متنی درباره فناوری باشد اما از کلمات مرتبط دیگری مانند mobile و digital استفاده کرده و هرگز کلمه technology را به کار نبرده باشد، در جست‌وجوی کوله کلمات به کلی نادیده گرفته می‌شود (مشکل معروف به عدم تطابق واژگانی / Vocabulary Mismatch).

اما در فضای نهان (پس از تجزیه SVD)، کلماتی که در بافت‌های مشابهی به کار می‌روند (مانند technology, mobile, digital که همگی در همان مؤلفه نهان «فناوری» بار بالایی دارند) به بردارهای نزدیک به هم در فضای C بعدی نگاشت می‌شوند. بنابراین اگر بردار پرس‌وجوی technology را با بردار نهان متنی که فقط شامل mobile و digital است مقایسه کنیم (مثلاً با Cosine Similarity)، شباهت بالایی به دست می‌آید، هرچند کلمه technology هرگز در آن متن ظاهر نشده است. به این ترتیب، جست‌وجو در فضای نهان می‌تواند اسناد مرتبط از نظر مفهومی را نیز بازبایی کند، نه فقط اسنادی که دقیقاً همان کلمه کلیدی را دارند؛ این دقیقاً همان قابلیت است که LSI را برای بازبایی اطلاعات (Information Retrieval) و بهینه‌سازی موتور جست‌وجو (SEO) مفید می‌کند.

مزیت محاسباتی

فضای کوله کلمات ابعادی برابر با تعداد کل کلمات واژگان دارد (در دادگان بزرگ می‌تواند ده‌ها یا صدها هزار بعد باشد)، در حالی که فضای نهان تنها C بعد دارد (در اینجا $C = 13$ که بسیار کوچک‌تر از تعداد کلمات و اسناد است). محاسبه شباهت (ضرب داخلی یا فاصله) بین بردارها در فضایی با ابعاد بسیار کمتر، هم از نظر حافظه موردنیاز برای نگهداری بردارها و هم از نظر زمان محاسبه شباهت‌ها (که به طور خطی با تعداد ابعاد رشد می‌کند)، به مراتب ارزان‌تر است؛ به‌ویژه وقتی این جست‌وجو باید بین یک پرس‌وجو و میلیون‌ها سند انجام شود، این کاهش بعد صرفه‌جویی محاسباتی بسیار چشمگیری ایجاد می‌کند.

سؤال ۱۹ — بردار نهان میانگین هر دسته و پیشنهاد روش برچسب‌گذاری

برچسب موضوعی متون به این صورت کدگذاری شده است:

کد	0	1	2	3	4
دسته	Politics	Sport	Technology	Entertainment	Business

برای متون هر دسته (در داده آموزش)، میانگین بردار نهان‌شان (سطر متناظر در $\bar{U}$) محاسبه و در یک نقشه گرمایی (Heat Map) با محور افقی دسته‌ها و محور عمودی مؤلفه‌های نهان نمایش داده شده است.

روش پیشنهادی برچسب‌گذاری (بدون نیاز به تفسیر معنای مؤلفه‌ها)

روش نزدیک‌ترین مرکز ثقل (Nearest Centroid Classifier) در فضای نهان پیشنهاد می‌شود:

۱. برای هر یک از ۵ دسته، بردار نهان میانگین تمام متون آموزشی آن دسته محاسبه می‌شود (همان ماتریسی که در نمودار بالا رسم شد؛ هر ستون آن یک بردار C بعدی است).

۲. برای برچسب‌گذاری یک متن جدید، ابتدا بردار کوله کلمات آن با میانگین و انحراف‌معیار داده آموزش استاندارد و سپس با استفاده از بردارهای تکین راست آموزش‌دیده ($\tilde{V}$) و مقادیر تکین ($\tilde{\Sigma}$) به فضای نهان تصویر می‌شود:

۳. این بردار با بردار مرکز ثقل هر ۵ دسته سنجیده می‌شود و برچسب دسته‌ای که بیشترین شباهت را دارد به آن متن نسبت داده می‌شود.

$$u_{new} = x_{std} \cdot \tilde{V} \cdot \tilde{\Sigma}^{-1}$$

مزیت این روش این است که هیچ نیازی به دانستن معنای هر کدام از مؤلفه‌های نهان ندارد؛ صرفاً از نزدیکی هندسی بردار متن جدید به مرکز ثقل هر دسته در فضای C بعدی استفاده می‌کند، دقیقاً مشابه یک طبقه‌بند نزدیک‌ترین همسایه اما در سطح مراکز دسته‌ها، که مقیاس‌پذیر و مستقل از تفسیر انسانی هر بُعد است.

سؤال ۲۰ — پیاده‌سازی و ارزیابی روش برچسب‌گذاری روی داده آزمون

روش نزدیک‌ترین مرکز ثقل معرفی‌شده در بخش قبل پیاده‌سازی و دقت آن روی داده‌های آزمون (۲۲۵ ردیف کنارگذاشته‌شده) سنجیده شده است. دقت هر دسته نیز به صورت مجزا گزارش شده است:

دسته	تعداد نمونه در آزمون	دقت
Politics	۰	—
Sport	۰	—
Technology	۰	—
Entertainment	۰	—
Business	۲۲۵	0.8267
دقت کلی (Overall Accuracy)	۲۲۵	0.8267

نکته دربار توزیع داده آزمون

از آنجا که دادگان اصلی بر اساس دسته‌بندی موضوعی مرتب شده‌اند و طبق دستور پروژه تفکیک آموزش/آزمون به صورت خام (بدون درهم‌ریزی) و صرفاً بر اساس ۲۰۰۰ ردیف اول / ۲۲۵ ردیف آخر انجام شده، تمام ۲۲۵ نمونه آزمون متعلق به یک دسته (Business) هستند. به همین دلیل دقت به تفکیک دسته تنها برای این دسته قابل محاسبه است و با دقت کلی برابر است. اگر هدف ارزیابی متوازن روی هر پنج دسته بود، لازم بود پیش از تفکیک آموزش/آزمون، داده‌ها درهم‌ریزی می‌شدند؛ اما طبق صورت پروژه این کار مجاز نبوده و ۲۰۰۰ ردیف اول باید بدون تغییر ترتیب به عنوان آموزش در نظر گرفته می‌شدند.

با این حال، دقت به دست‌آمده (حدود 82.7٪) نشان می‌دهد روش نزدیک‌ترین مرکز ثقل در فضای نهان، حتی با تنها ۱۳ مؤلفه نهان و ۵۲ کلمه منتخب، توانسته اکثر متون دسته Business را به درستی تشخیص دهد؛ این موفقیت، کارایی نمایش فضای نهان LSI را برای دسته‌بندی متون بدون نیاز به تفسیر معنایی مؤلفه‌ها تأیید می‌کند.